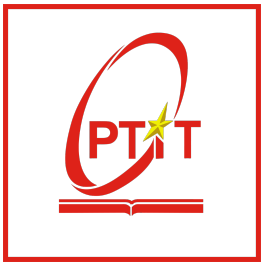
HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN 1



BÁO CÁO THỰC HÀNH AGENT 02

MÔN HỌC: PHÁT TRIỂN CÁC HỆ THỐNG THÔNG MINH

REINFORCEMENT LEARNING VÀ RULE-BASED AGENTS

Giảng viên hướng dẫn	:	PGS.TS. Trần Đình Quế
Lớp	:	D23CTPM01
Nhóm học phần	:	CT01
Sinh viên thực hiện	:	Nguyễn Nam Hải
Mã sinh viên	:	B23DCCN277

Hà Nội – Năm 2026

MỤC LỤC

Danh mục thuật ngữ **iv**

1 Giới thiệu và mục tiêu thí nghiệm **1**

2 Mô tả môi trường và hai tác tử **1**
2.1 Mô hình thị trường . . . 1
2.2 Agent A: Q-learning . . . 1
2.3 Agent B: luật cố định . . . 2
2.4 Hai vấn đề trạng thái cần lưu ý . . . 2

3 Mã nguồn và thay đổi so với tài liệu tham chiếu **2**

4 Thiết lập thực nghiệm và protocol **3**

5 Thí nghiệm A — Baseline và policy đã học **4**

6 Thí nghiệm B — Quá trình học **4**

7 Thí nghiệm C — Learning rate **5**

8 Thí nghiệm D — Khám phá **5**

9 Thí nghiệm E — So sánh policy công bằng **5**

10 Trả lời đầy đủ mười câu hỏi **6**
10.1 Câu 1 — Mô hình tác tử và môi trường . . . 6
10.2 Câu 2 — Quyết định học và theo luật . . . 6
10.3 Câu 3 — Tính cập nhật Q-learning . . . 6
10.4 Câu 4 — Khám phá và khai thác . . . 7
10.5 Câu 5 — Reward và mục tiêu kinh doanh . . . 7
10.6 Câu 6 — Hiệu năng và thống kê . . . 7
10.7 Câu 7 — Learning rate và ổn định . . . 8
10.8 Câu 8 — Tương tác và môi trường không dừng . . . 8
10.9 Câu 9 — Giới hạn và biến đổi đã thực hiện . . . 9
10.10 Câu 10 — Thiết kế agent tốt hơn . . . 9

11 Phân tích bổ sung: lợi nhuận, oracle và độ nhạy **10**
11.1 Bảng lợi nhuận kỳ vọng . . . 10
11.2 Giải thích mốc 35 và quy hoạch động . . . 10
11.3 Ngưỡng discount có lợi tức thời . . . 10

12 Thảo luận về độ tin cậy, giới hạn và diễn giải **11**

13 Kiểm tra độc lập bằng đánh giá policy chính xác **11**

14 Kết luận của assignment **12**

15 Phụ lục kết quả đo và bằng chứng thực thi **12**
15.1 Bảng tổng hợp thí nghiệm alpha và epsilon 12
15.2 So sánh công bằng với cùng đối thủ 12
15.3 Thí nghiệm biến đổi discount 40% 12
15.4 Q-table minh họa seed 42 13
15.5 Từng seed của baseline 13
15.6 Cặp learner trong self-play 13
15.7 Đối chiếu bản gốc và bản mở rộng seed 42 14
15.8 Mã Python cốt lõi 16
15.9 Bằng chứng kiểm thử 17

Tài liệu tham khảo **18**

DANH MỤC HÌNH VẼ

1 Learning curve baseline: moving average 100 episode, mean và một SD qua năm seed. 14
2 So sánh ba learning rate với cùng epsilon schedule. 14
3 So sánh ba cấu hình epsilon; mọi cấu hình đánh giá với epsilon bằng 0. . . . 15
4 Policy đóng băng: mean và SD giữa seed; đường 35 là kỳ vọng lý thuyết. . . 15
5 Q-table seed 42 và độ nhạy lợi nhuận tức thời theo discount fraction. 15

DANH MỤC THUẬT NGỮ

MAS	Multi-Agent System – Hệ đa tác tử
LLM	Large Language Model – Mô hình ngôn ngữ lớn
RL / MARL	Reinforcement Learning / Multi-Agent RL
MDP / POMDP	Quá trình quyết định Markov / quan sát không đầy đủ
TD / Q	Sai phân thời gian / Giá trị hành động
DP	Dynamic Programming – Quy hoạch động
OOD	Out-of-distribution – Ngoài phân phối/ngoài miền
PEAS	Performance, Environment, Actuators, Sensors
DAG	Directed Acyclic Graph – Đồ thị có hướng không chu trình
SD / CI	Độ lệch chuẩn mẫu / Khoảng tin cậy
P50 / P95	Phân vị 50 / 95 của thời gian phản hồi
TTL	Time to Live – Giới hạn độ mới của dữ liệu

Quy ước đọc báo cáo

Dữ liệu thực hành là tổng hợp hoặc mô phỏng. Số đo được lấy từ mã đã chạy và lưu kèm; phép tính lý thuyết và đề xuất chưa thực hiện được gọi rõ. Thông tin bìa, logo và phong cách trình bày kế thừa báo cáo trước. Ngày hoàn thiện: 28/10/2026.

1 Giới thiệu và mục tiêu thí nghiệm

Laboratory Experiment 02 yêu cầu triển khai và so sánh reinforcement-learning-based agent với rule-based agent trong thị trường thương mại điện tử đơn giản. Báo cáo hoàn thành thí nghiệm A–E, giải đủ mười câu hỏi, triển khai biến đổi môi trường, thử đồng học và xây dựng một agent mốc tốt hơn bằng quy hoạch động. Các kết quả trong bảng và hình được tạo từ mã chạy thật; dữ liệu thị trường là mô phỏng, không phải số liệu kinh doanh thực tế. [2]

Theo đề, hạn nộp là 23:30 thứ Năm ngày 29/10/2026. Tên tệp theo quy ước và thông tin kế thừa từ bài trước là `agent02_CT_04_hainn.pdf`. Bìa sử dụng PTIT, lớp D23CTPM01, nhóm học phần CT01, Nguyễn Nam Hải, mã B23DCCN277 và giảng viên PGS.TS. Trần Đình Quế. Các thông tin này lấy từ báo cáo trước trong workspace.

Có ba mục tiêu đánh giá riêng: hành vi học thay đổi thế nào qua tương tác; policy đóng băng đạt lợi nhuận bao nhiêu; và kết quả có ổn định khi thay seed hoặc tham số môi trường không. Một đường reward tăng không tự trả lời hai câu sau. Báo cáo vì thế tách training, evaluation, fair policy comparison và robustness.

2 Mô tả môi trường và hai tác tử

2.1 Mô hình thị trường

Hai cửa hàng A và B chọn đồng thời hành động $a_i \in \{0, 1\}$, lần lượt là không giảm và giảm giá. Không agent nào được nhìn hành động hiện tại của đối thủ trước khi chọn. Mỗi bên quan sát nhu cầu $d \in \{0, 1\}$ và hành động trước của đối thủ. Không gian quan sát cục bộ có bốn phần tử và hai hành động nên bảng Q tham chiếu có tám giá trị.

Nhu cầu thấp có 10 khách hàng tiềm năng, nhu cầu cao có 20. Xác suất chuyển đổi cho agent i là:

$$p_i = \text{clip}(0.30 + 0.25d + 0.15a_i - 0.10a_{-i}, 0.05, 0.95).$$

Doanh số $S_i \sim \text{Binomial}(N_d, p_i)$; giá gốc $P = 10$, unit cost $C = 5$, discount fraction $\delta = 0.20$; reward:

$$r_i = S_i \left[P(1 - \delta a_i) - C\right].$$

Nhu cầu tiếp theo lấy đều độc lập; hành động hiện tại trở thành lịch sử của bước sau. Sales hai cửa hàng được lấy mẫu riêng có điều kiện theo nhu cầu và hành động, không có ràng buộc tổng sales không vượt một nhóm khách hàng duy nhất. Vì vậy đây là mô hình tương tác cạnh tranh có tổng lợi ích thay đổi, không phải mô phỏng thị phần đầy đủ hoặc trò chơi tổng bằng không.

2.2 Agent A: Q-learning

Agent A dùng bảng $Q[d, c, a]$. Trong training, nó khám phá theo epsilon-greedy và cập nhật:

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)].$$

Bước cuối dùng target r vì được coi là terminal trong protocol tham chiếu. Evaluation dùng argmax xác định, epsilon 0 và không gọi learn. Phân xử hòa trong evaluation chọn action 0; training phá hòa ngẫu nhiên. Quy ước này được công bố vì các policy snapshot cần cho cùng kết quả khi chạy lại.

2.3 Agent B: luật cố định

Luật là $\pi_B(d,c) = 1$ khi $d = 1$ và $c = 1$, còn lại bằng 0. Khi nhu cầu thấp, B không giảm. Khi nhu cầu cao, B chỉ giảm nếu A đã giảm ở bước trước. B không cập nhật từ reward và không có bảng Q. Tuy nhiên, hành động của B vẫn phụ thuộc quan sát và có thể thay đổi theo thời gian; không học không đồng nghĩa luôn có cùng một hành động.

2.4 Hai vấn đề trạng thái cần lưu ý

Quan sát cục bộ của A thiếu hành động trước của chính A, trong khi luật B sử dụng đúng bit đó. Với cùng $(d = 1, c_B = 0)$, B có thể chọn 0 hoặc 1 tùy hành động trước của A. Vì vậy quan sát tham chiếu không đảm bảo Markov đối với learner. Mã giữ nó để so sánh đúng baseline, nhưng báo cáo không áp một định lý MDP đầy đủ lên biểu diễn này.

Episode có 20 bước và target terminal ở cuối, nhưng bảng Q không chứa thời gian. Một quan sát ở đầu kỳ và cuối kỳ nhận các target có độ dài tương lai khác nhau. Đây là vấn đề hữu hạn chân trời bị gộp trong một bảng. Agent cải tiến dùng trạng thái đầy đủ và chỉ số thời gian, được trình bày ở Câu 10.

3 Mã nguồn và thay đổi so với tài liệu tham chiếu

Tệp `assignment/reference_agent02.py` là bản sao nguyên văn chương trình được cung cấp trong `agent02_code.tex`, lưu riêng để đối chiếu. Tệp `assignment/agent02_experiment.py` triển khai môi trường, Q-learning, luật, train, evaluate và chương trình xuất dữ liệu. Mã gốc được chạy thêm riêng cho seed 42; kết quả lưu với tiền tố `reference_original_42`.

Các thay đổi được công bố rõ: tách stream random nhu cầu, sales và agent bằng SeedSequence; đánh giá vector hóa theo episode với common random numbers; dùng cùng opponent cho so sánh policy; chạy toàn bộ cấu hình trên năm seed; xuất learning curves cho cả alpha và epsilon; bổ sung discount 40%, self-play và oracle DP. Quy luật phân phối nhu cầu, conversion, sales và margin được giữ nguyên cho baseline.

Tách RNG không tạo ra cùng chuỗi số ngẫu nhiên như chương trình gốc dù cùng seed số học. Vì vậy kết quả baseline 42 của bản mở rộng **không được gọi là tái lập bit-for-bit** của code gốc. Đó là một thực nghiệm cùng mô hình phân phối với protocol random rõ hơn. Sự khác biệt này còn được kiểm tra bằng việc chạy bản gốc riêng và đưa cả hai vào phụ lục số liệu.

Common random numbers trong evaluation được tạo bằng cùng demand tape và cùng

tensor uniform Bernoulli cho mọi focal policy trên một seed. Nếu xác suất chuyển đổi tăng, cùng uniform cho phép so sánh có ghép cặp; số lượng sales vẫn có phân phối binomial đúng. Khi policy làm lịch sử khác đi, reward có thể khác, nhưng nhiễu đầu vào được kiểm soát tốt hơn so với hai lần chạy hoàn toàn độc lập.

4 Thiết lập thực nghiệm và protocol

Tham số	Giá trị
Training episodes	5.000 mỗi lần train
Steps/episode	20
Evaluation episodes	500
Evaluation steps	10.000 mỗi cặp policy/seed
Gamma	0.90
Alpha baseline	0.10
Epsilon baseline	max(0.02, 0.20 × 0.995ˆepisode_index)
Alpha sensitivity	0.01, 0.10, 0.50
Epsilon sensitivity	Schedule baseline; fixed 0.05; fixed 0.30
Training seeds	11, 22, 33, 44, 55; run minh họa riêng seed 42
Evaluation seeds	800000 + training seed
Evaluation riêng seed 42	500042
Self-play evaluation	900000 + training seed
Discount robustness	40%, giữ các tham số còn lại

Năm seed được dùng nhất quán cho mỗi cấu hình alpha/epsilon. Mỗi cấu hình có 500.000 bước training cộng 50.000 bước evaluation. Toàn bộ baseline và mở rộng có 36 lượt training của chương trình mở rộng: 25 lượt sensitivity, một lượt minh họa seed 42, năm lượt retrain discount 40% và năm lượt self-play. Tính theo môi trường là 3.600.000 bước training; các lượt self-play cập nhật hai Q-table mỗi bước.

Đơn vị reward trong báo cáo là đơn vị lợi nhuận của mô hình, không được gán thành VND hoặc USD vì đề không quy định tiền tệ. Reward trung bình tính bằng tổng profit chia tổng bước. Standard deviation trong bảng cấu hình là sample SD trên năm **run means**, không phải SD của toàn bộ từng bước. SD từng episode được lưu riêng trong summary và không thay thế biến động giữa seed.

Khoảng tin cậy minh họa cho mean qua năm seed dùng $t_{0.975,4} = 2.776$, tức $\bar{x} \pm 2.776s/\sqrt{5}$. Với chỉ năm seed và policy phân phối có thể không chuẩn, khoảng này có tính xấp xỉ và dễ rộng. Báo cáo không dùng nó như bằng chứng chắc chắn về mọi môi trường hoặc mọi lần train.

5 Thí nghiệm A — Baseline và policy đã học

Lượt minh họa mở rộng seed 42 cho focal RL tổng reward 255591, trung bình 25.5591 trên 10.000 bước; opponent rule tổng 246856, trung bình 24.6856. RL không giảm 1849 lần và giảm 8151 lần, tức 81.51%; opponent giảm 38.53%. Đây là một policy seed cụ thể có chất lượng thấp so với mốc không giảm giá, không phải con số đại diện duy nhất cho Q-learning.

Bảng Q đầy đủ và policy ở bốn trạng thái được sinh từ `baseline_42_q.npy`, hiển thị ở phần số liệu tự động cùng heatmap. Vì reward discounted dài hạn có thể lớn hơn reward tức thời, độ lớn Q không được so trực tiếp với profit mỗi bước. Việc Q lớn chưa chứng minh greedy action đúng; phải đánh giá policy và đối chiếu oracle.

Ở năm seed dùng cho so sánh chính, baseline RL đạt mean 34.0997, SD 1.3678. Hai seed 22 và 33 học policy còn giảm giá đáng kể, các seed 11, 44 và 55 đạt hành vi không giảm ở các trạng thái đã gặp trong evaluation. Chênh lệch lớn giữa seed 42 và nhóm năm seed là bằng chứng rất rõ về rủi ro kết luận từ một lần chạy.

Cũng cần lưu ý reward đối thủ trong cùng trận không phải baseline tách biệt cùng đối thủ. Khi A giảm, B có thể phản ứng; hai bên không có cùng chuỗi quyết định. Vì vậy việc RL 25.56 cao hơn opponent 24.69 ở seed 42 không chứng minh RL tốt hơn mọi rule policy. Thí nghiệm E mới so sánh các focal policy dưới cùng opponent cố định.

6 Thí nghiệm B — Quá trình học

Learning curve dùng reward/step mỗi episode, làm trơn bằng trung bình trượt 100 episode. Trục x gắn với cuối cửa sổ; hình tổng hợp thể hiện mean và vùng ±1 SD trên năm seed. Đó là cửa sổ trượt có chồng lấn, vì vậy các điểm liên tiếp không độc lập thống kê. Số liệu episode thô vẫn được giữ trong CSV.

Baseline có trung bình 500 episode đầu là 32.8595 và 500 episode cuối là 33.6718. Quan sát này phù hợp với việc policy cải thiện một phần trong training, nhưng mức tăng khoảng 0.8124 không chứng minh hội tụ hoặc tối ưu. Các đường còn dao động do nhu cầu, sales, khám phá và cập nhật Q.

Nếu nhìn cả training mean 33.6513 và frozen evaluation mean 34.0997, evaluation cao hơn trong nhóm seed này. Một giải thích phù hợp là tắt khám phá giảm chi phí thử hành động. Tuy nhiên, không nên quy mọi chênh lệch cho epsilon vì evaluation dùng dữ liệu khác và policy cuối chỉ là một snapshot. Các giới hạn về aliasing và thời gian vẫn tồn tại khi epsilon bằng 0.

Để nghiên cứu hội tụ sâu hơn, cần lưu Q qua các checkpoint, đo thay đổi policy, visit counts và regret so với oracle. Bộ bài hiện đã cung cấp bảng Q cuối, learning curve và nhiều seed; chưa thực hiện chuỗi checkpoint lớn nên không đưa kết luận về tốc độ hội tụ chính xác.

7 Thí nghiệm C — Learning rate

Ba alpha 0.01, 0.10 và 0.50 giữ nguyên gamma, số episode và epsilon schedule. Mean đánh giá lần lượt 33.6484, 34.0997 và 31.9533; SD giữa seed lần lượt 2.1286, 1.3678 và 4.1613. Trong những run đã đo, alpha 0.10 có mean cao và biến động thấp hơn hai lựa chọn còn lại.

Alpha 0.01 tăng training từ 30.9924 ở 500 episode đầu lên 33.7541 ở 500 episode cuối, cho thấy việc cập nhật chậm có thể cần nhiều tương tác. Alpha 0.50 có SD đánh giá lớn, phù hợp với độ nhạy cao trước nhiễu reward và target. Nhưng dữ liệu này không đủ để nói learning rate 0.50 luôn gây bất ổn trong mọi môi trường.

Một điểm kỹ thuật là target terminal giảm mạnh ở cuối mỗi episode. Alpha lớn đưa trọng số lớn hơn cho các mẫu đó, trong khi state không chứa thời gian. Do vậy tác động alpha bị trộn với thiết kế biểu diễn. Muốn tách nguyên nhân, cần thêm ablation Q có chỉ số thời gian trên cùng alpha; đây là thí nghiệm được đề xuất chứ chưa được báo như đã chạy.

8 Thí nghiệm D — Khám phá

Schedule baseline, epsilon cố định 0.05 và cố định 0.30 cho mean evaluation lần lượt 34.0997, 33.3973 và 31.4300; SD lần lượt 1.3678, 1.6126 và 3.9272. Mean training tương ứng 33.6513, 32.9458 và 30.8822. Cấu hình khám phá cao không có lợi trong bộ run hiện tại.

Mức epsilon 0.30 không có nghĩa 30% bước chắc chắn chọn hành động không greedy. Với hai action, nhánh ngẫu nhiên vẫn có xác suất chọn greedy. Ngoài ra, tỷ lệ discount cuối còn phụ thuộc policy đã học, nên discount rate evaluation không bằng epsilon training. Báo cáo ghi riêng các đại lượng trong CSV để tránh đồng nhất chúng.

Tắt khám phá trong evaluation cần thiết để đo policy greedy, nhưng không sửa một bảng Q đã học sai. Đối với seed học ra lựa chọn discount không tốt, epsilon 0 làm lựa chọn đó lặp nhất quán. Vì vậy thiết kế khám phá cần được đánh giá bằng cả hiệu năng trong training, chất lượng cuối và biến động giữa seed.

9 Thí nghiệm E — So sánh policy công bằng

Focal policies gồm Q-learning, rule tham chiếu, luôn không giảm, luôn giảm và DP. Tất cả được đánh giá với cùng rule opponent, cùng seeds và cùng random tapes. Không cập nhật bất kỳ Q nào. Đây là phép so sánh phù hợp hơn việc chỉ đặt reward hai bên của một trận cạnh nhau.

Rule và never-discount đạt cùng hành vi khi cả hai lịch sử khởi đầu bằng 0. DP cũng chọn không giảm ở mọi state/time với tham số mặc định. Do cùng action và tape, ba hàng này có số đo giống hệt nhau từng seed. Mean khoảng 35.1295 không phải 35 đúng tuyệt đối; 35 là kỳ vọng lý thuyết, số đo hữu hạn có nhiễu.

RL baseline đạt 34.0997; mức kém hơn rule trên nhóm seed này khoảng 1.0298 lợi nhuận/step. Đây là kết quả trong môi trường tham chiếu. Nó không chứng minh rule tốt hơn RL ở mọi bài toán; thay đổi conversion, chi phí, đối thủ hoặc state có thể tạo kết quả

khác. Điều có thể kết luận là baseline Q-learning hiện tại chưa vượt được một policy xác định rất đơn giản trong mô hình này.

10 Trả lời đầy đủ mười câu hỏi

10.1 Câu 1 — Mô hình tác tử và môi trường

Hai tác tử là hai cửa hàng chọn giảm giá. Môi trường gồm nhu cầu, lịch sử hành động, quá trình sales và quy tắc profit. Observation mỗi agent là (d, c); action gồm 0/1; reward là lợi nhuận đã trừ unit cost sau giảm giá; chuyển tiếp cập nhật lịch sử và sinh nhu cầu mới. Bốn observation kết hợp hai action tạo tám mục Q.

Đây là MAS vì reward của mỗi bên phụ thuộc hành động bên kia qua hệ số $-0.10a_{-i}$ và quan sát tương lai chứa hành động đối thủ. Hai policy có mục tiêu lợi nhuận riêng và quyết định tương tác. Không có thông điệp chat vẫn có thể là MAS: môi trường chung là kênh tương tác. Khi giữ opponent cố định, có thể phân tích learner như bài điều khiển trong một môi trường hiệu dụng, nhưng bản chất hệ gốc vẫn có hai tác tử.

Phân biệt observation với full state là cần thiết. Trạng thái đầy đủ $x = (d, a^A_{t-1}, a^B_{t-1})$ có tám tổ hợp, thêm thời gian nếu hữu hạn chân trời. Observation tham chiếu chỉ là một phép chiếu của full state. Nêu điều này giúp tránh gọi bốn observation là một MDP đầy đủ mà chưa kiểm giả định.

10.2 Câu 2 — Quyết định học và theo luật

RL chọn theo bảng giá trị được điều chỉnh từ reward; rule chọn theo điều kiện do người thiết kế viết. RL cần nhiều mẫu, RNG, bảng Q và công đoạn train; rule không cần tối ưu tham số. Trong inference của bài nhỏ này, cả hai đều rất nhẹ nên chi phí tính toán không phải yếu tố phân biệt lớn nhất. Chi phí thu thập trải nghiệm mới đáng lưu ý.

RL có khả năng thích nghi khi tiếp tục học và được cung cấp thông tin/reward phù hợp, nhưng một policy đóng băng không tự thích nghi chỉ vì tên của nó có chữ learning. Rule có thể phản ứng với đầu vào thay đổi mà không học. Khi môi trường đổi, cả hai đều có thể kém nếu biểu diễn hoặc luật không phù hợp.

Rule phù hợp cho điều kiện nghiệp vụ rõ, ít dữ liệu và cần giải thích, ví dụ không bán dưới giá vốn hoặc ngưỡng khuyến mãi đã được phê duyệt. RL phù hợp hơn khi có tương tác lặp, phản hồi đo được, mô phỏng đủ tin cậy và không biết trước chiến lược tốt. Trong chính môi trường hiện tại, policy không giảm rất mạnh; dùng RL chưa tạo lợi ích chỉ nhờ có học.

10.3 Câu 3 — Tính cập nhật Q-learning

Dữ kiện: $Q(s,a) = 4$, $\alpha = 0.1$, $r = 6$, $\gamma = 0.9$, $\max_{a'} Q(s', a') = 5$.

1. Giá trị tương lai sau chiết khấu: $0.9 \times 5 = 4.5$.
2. TD target: $y = 6 + 4.5 = 10.5$.
3. TD error: $\Delta = y - Q = 10.5 - 4 = 6.5$.

4. Mức thay đổi: $\alpha\Delta = 0.1 \times 6.5 = 0.65$.
5. Giá trị mới: $Q_{new} = 4 + 0.65 = \mathbf{4.65}$.

Agent nâng giá trị vì trải nghiệm mới gợi ý return cao hơn dự đoán. Nó chỉ đi 10% khoảng cách đến target để không tin hoàn toàn một mẫu có nhiễu. Con số này là ví dụ giả định của câu hỏi, không phải đo từ thị trường. Test `test_update_example` xác nhận kết quả.

Nếu transition terminal, không dùng giá trị 5 ở tương lai: target 6 và Q mới 4.2. Test terminal riêng dùng Q tương lai rất lớn để đảm bảo implementation không bootstrap nhầm. Hai phép kiểm tách công thức nonterminal và điều kiện kết thúc.

10.4 Câu 4 — Khám phá và khai thác

Khám phá giúp có dữ liệu về các hành động ít được chọn; khai thác tận dụng hành động có Q cao. Nếu dừng khám phá quá sớm, một reward xấu ban đầu có thể làm agent bỏ một lựa chọn tốt. Nếu khám phá quá nhiều, nó chịu chi phí thử và có thể tác động xấu đến đối thủ trong các bước tiếp theo.

Thực nghiệm schedule so với epsilon cố định 0.30 cho training mean 33.6513 so với 30.8822 và frozen mean 34.0997 so với 31.4300. Chênh lệch khoảng 2.77 ở training và 2.67 ở evaluation hỗ trợ nhận định schedule tốt hơn trong nhóm run này. Fixed 0.05 nằm giữa về mean evaluation 33.3973 nhưng chưa vượt schedule.

Đây không phải bằng chứng epsilon càng thấp càng tốt, vì fixed 0.05 vẫn thấp hơn schedule trong kết quả đo. Đầu kỳ khám phá, cuối kỳ khai thác và nhiễu học tương tác với nhau. Muốn chọn epsilon để triển khai, cần validation riêng; không nên tuning trên chính test đã báo cuối.

10.5 Câu 5 — Reward và mục tiêu kinh doanh

Không giảm: margin $10 - 5 = 5$ mỗi sale. Giảm 20%: giá còn $10(1 - 0.20) = 8$, margin $8 - 5 = 3$. Discount tăng conversion thêm 0.15 nhưng giảm margin 40%. Lợi nhuận tăng hay giảm phụ thuộc tích của số sale kỳ vọng và margin, không chỉ một yếu tố.

Nhu cầu thấp và đối thủ không giảm: không giảm kỳ vọng $10 \times 0.30 \times 5 = 15$; giảm kỳ vọng $10 \times 0.45 \times 3 = 13.5$. Sales kỳ vọng tăng từ 3 lên 4.5, nhưng profit giảm 1.5. Nhu cầu cao và đối thủ không giảm: profit từ 55 xuống 42 dù sales từ 11 lên 14. Hai ví dụ trực tiếp giải thích vì sao tối ưu conversion khác tối ưu profit.

Nếu reward là sales, discount có thể được ưu tiên vì hệ số chuyển đổi cao hơn. Nếu thêm reward cho khách hàng quay lại, agent có thể chấp nhận profit tức thời thấp hơn; muốn mô tả điều này cần thêm trạng thái về khách hàng hoặc mô hình tác động tương lai. Nếu có quy định margin tối thiểu, nên hạn chế hành động hợp lệ thay vì chỉ cộng penalty nhỏ.

10.6 Câu 6 — Hiệu năng và thống kê

Công thức là $\bar{r}_i = \sum_{t=1}^{T} r_i(t)/T$. Với lượt minh họa seed 42, $T = 500 \times 20 = 10000$, RL là $255591/10000 = 25.5591$ và rule đối thủ là $246856/10000 = 24.6856$. Đây là cách tính trên dữ liệu thật, minh họa rõ quan hệ giữa total reward và average reward.

So sánh công bằng tách biệt dùng cùng rule opponent và tape: RL baseline có mean qua năm seed 34.0997, rule khoảng 35.1295, never/DP giống rule trên các run đã đo. Bảng chi tiết từng seed và các cấu hình được tạo tự động từ CSV ở phần bằng chứng. Đơn vị sample để tính SD cấu hình là run mean, tránh coi hàng chục nghìn bước tương quan là độc lập.

Một run không đủ vì training RNG thay đổi hành động khám phá, sales noise thay đổi cập nhật, và policy cuối có thể mắc ở hành vi khác. Seed 42 cho kết quả rất thấp trong khi ba seed khác chọn không giảm trong evaluation. Ngoài biến động random, một mô hình toy không đại diện mọi thị trường; nhiều seed chỉ giải quyết một phần độ tin cậy nội bộ.

10.7 Câu 7 — Learning rate và ổn định

Alpha 0.01, 0.10, 0.50 có frozen mean 33.6484, 34.0997, 31.9533 và SD 2.1286, 1.3678, 4.1613. Những số này được đo với cùng seed set và các thông số khác được giữ. Alpha 0.10 có kết quả tốt nhất trong ba lựa chọn ở thí nghiệm hiện tại, không phải khuyến nghị phổ quát.

Alpha thấp giảm trọng lượng của từng mẫu mới, nên phản ứng chậm; nó tăng đáng kể từ đầu đến cuối training trong nhóm đo. Alpha cao phản ứng nhanh nhưng cũng nhạy với reward ngẫu nhiên và target bị gộp thời gian. Policy cuối alpha 0.50 có biến động lớn giữa seed. Đây là quan sát phù hợp với giả thuyết nhiễu cập nhật, chưa phải thí nghiệm tách nguyên nhân hoàn toàn.

Cần tránh dùng từ "hội tụ" chỉ vì đường được làm trơn tương đối phẳng. Alpha cố định, trạng thái cục bộ thiếu và 20 bước hữu hạn làm các điều kiện lý thuyết không được đáp ứng đầy đủ. Phân tích ổn định nên bổ sung policy flip rate hoặc khoảng cách Q tới mốc trong các thí nghiệm tiếp theo.

10.8 Câu 8 — Tương tác và môi trường không dừng

Discount của đối thủ giảm conversion của agent 0.10, đồng thời trở thành observation cục bộ ở bước tiếp. Hành động của agent cũng ảnh hưởng rule opponent ở tương lai. Vì vậy quyết định hiện tại có thể tác động cả reward tức thời và chuỗi reward sau, dù nhu cầu độc lập.

Khi hai Q learner cập nhật đồng thời, một agent thu thập dữ liệu từ policy đối thủ đang đổi. Đối với cùng trạng thái và hành động cục bộ, phân phối kết quả hiệu dụng có thể thay đổi qua thời gian. Các target trước đây vì thế không còn phản ánh cùng một môi trường. Đây là non-stationarity do đồng học, khác với stochasticity của sales trong một policy cố định.

Báo cáo **đã triển khai** self-play: hai Q learner cùng train 5.000 episode trên năm seed, rồi đóng băng cả hai và đánh giá riêng. Seed 11 có hai mean 30.5514 và 32.5935; các seed khác gần hành vi không giảm và quanh 35. Những số này cho thấy phụ thuộc seed, không chứng minh nguyên nhân mọi lỗi là non-stationarity hoặc đạt Nash equilibrium.

Thí nghiệm tiếp theo để nghiên cứu sâu hơn là freeze một bên theo từng giai đoạn, lưu policy checkpoint và cross-play các cặp khác seed. Giữ cùng số bước và dữ liệu demand/sales để đối chiếu với simultaneous learning. Chỉ khi đó mới có cơ sở phân tích vai trò của tốc độ

thay đổi đối thủ một cách rõ hơn.

10.9 Câu 9 — Giới hạn và biến đổi đã thực hiện

Ít nhất ba giới hạn chính: conversion tuyến tính là giả định minh họa; nhu cầu IID không có mùa vụ; sales hai cửa hàng không cạnh tranh qua ràng buộc thị phần chung. Ngoài ra, không có tồn kho, ngân sách quảng cáo, customer lifetime value, chi phí đổi giá hoặc heterogeneity khách hàng. Observation thiếu own previous action và Q không có thời gian làm hạn chế biểu diễn.

Biến đổi được triển khai là tăng discount fraction từ 20% lên **40%**. Giá giảm còn 6, margin còn 1; giữ nguyên tác động +0.15 lên conversion và các tham số khác để cô lập thay đổi margin trong mô hình. Đây là một stress test đối với cơ chế reward, không phải một khuyến nghị định giá thực tế.

Ba đối chiếu quan trọng là frozen RL từ môi trường cũ, retrained RL trong discount 40% và rule/DP. Frozen policy có discount ở seed 22/33 bị giảm mean từ khoảng 32.5–32.7 xuống 28.9–29.1; các seed không discount giữ nguyên reward trên cùng tape. Retraining không bảo đảm mọi seed sửa tốt: seed 33 còn mean 27.6282. Kết quả tổng hợp và từng seed được lưu trong robustness CSV.

Khi discount 40%, không giảm vẫn có margin 5 nên rule và DP giữ cùng hành vi và số đo baseline trên tape. Điều này giải thích tại sao một số hàng kết quả giống hệt, không phải dấu hiệu chép số. Thay đổi discount trong một môi trường còn đơn giản chưa chứng minh robustness toàn diện trước demand shift hoặc đối thủ mới.

10.10 Câu 10 — Thiết kế agent tốt hơn

Bản cải tiến đã thực thi là **finite-horizon model-based best response** bằng dynamic programming. State là (t, d, u, v), trong đó u và v là hành động trước của mình và đối thủ. Action vẫn 0/1; reward là profit theo đúng mô hình; transition dùng nhu cầu IID và $b = d\,u$ của rule opponent. Điều kiện cuối $V_H = 0$.

Với mỗi thời điểm đi ngược từ $H - 1$ về 0:

$$Q_t(x, a) = \bar{r}(x, a, b(x)) + \gamma \sum_{d' \in \{0,1\}} \frac{1}{2} V_{t+1}(d', a, b(x)), \qquad \pi_t(x) = \arg\max_a Q_t(x, a).$$

DP thêm thông tin cần thiết và xử lý đúng thời gian; với môi trường nhỏ và mô hình biết trước, nó là một mốc mạnh, minh bạch. Không có training samples nên không nên gọi là "Q-learning tốt hơn". So sánh phải ghi rõ lợi thế biết mô hình; đó là oracle trong môi trường mô phỏng đã xác định.

Đánh giá dùng cùng rule opponent, seeds và random tapes như RL/rule. Policy DP chọn không giảm và đạt cùng số đo với never/rule. Độ bền được kiểm thêm ở discount 40%, nhưng vì rule đã đồng hạng với DP trên cả hai chế độ, báo cáo **không tuyên bố agent cải tiến vượt cả hai baseline**. Nó sửa cách mô hình hóa và cung cấp chuẩn kiểm tra; muốn

chứng minh vượt rule cần môi trường nơi optimal action thực sự đổi.

Một hướng nghiên cứu tiếp theo là conversion uplift lớn hơn hoặc đối thủ khác, nơi giảm giá đôi khi có lợi; dùng learned model với uncertainty hoặc tabular Q theo state đầy đủ và thời gian. Huấn luyện trên nhiều regime, tách validation để chọn tham số, rồi test zero-shot và retrain trên regime mới. Đo profit, worst-case regret, constraint violations, chi phí dữ liệu và độ ổn định qua seed. Đây là protocol đề xuất, không có số liệu giả cho những thí nghiệm chưa chạy.

11 Phân tích bổ sung: lợi nhuận, oracle và độ nhạy

11.1 Bảng lợi nhuận kỳ vọng

Với các tham số mặc định, clip không hoạt động vì conversion luôn trong miền 0.20–0.70. Bảng dưới tính từ mô hình, không phải sample mean:

Demand	Action đối thủ	Không giảm	Giảm 20%	Chênh giảm trừ không giảm
Thấp	0	15.0	13.5	-1.5
Thấp	1	10.0	10.5	+0.5
Cao	0	55.0	42.0	-13.0
Cao	1	45.0	36.0	-9.0

Hàng thấp/đối thủ 1 cho thấy discount không luôn kém về reward tức thời trong mọi joint action. Nhưng rule opponent không chọn 1 khi demand thấp, nên hàng đó không thuộc hành vi hiện tại của đối thủ. Kết luận best response phải dùng policy đối thủ và động lực tương lai, không chỉ xem một hàng riêng.

11.2 Giải thích mốc 35 và quy hoạch động

Nếu A luôn chọn 0 và lịch sử đầu bằng 0, rule B luôn chọn 0. Reward A kỳ vọng 15 ở demand thấp và 55 ở demand cao; trung bình 35. Ở cả hai mức nhu cầu với B=0, action 0 tốt hơn tức thời và còn tránh kích hoạt B giảm ở bước sau. DP xác nhận policy 0 toàn bộ state/time, làm cơ sở kiểm tra numerical.

Mốc này là expected reward mỗi bước chưa chiết khấu. Giá trị DP đầu kỳ dùng gamma 0.9 sẽ là tổng geometric có chiết khấu, không bằng 20×35 trong biểu thức giá trị. Báo cáo không so trực tiếp V với episode profit. Đây là một điểm nhỏ nhưng quan trọng khi đọc Q-table và đồ thị.

11.3 Ngưỡng discount có lợi tức thời

Gọi $p_0 = 0.30 + 0.25d - 0.10b$, margin gốc $m = P - C = 5$ và uplift $u = 0.15$. Khi chưa clip, discount có lợi tức thời nếu $(p_0 + u)(m - P\delta) > p_0 m$, tức:

$$\delta < \frac{um}{P(p_0 + u)}.$$

Ở demand thấp, b=0, ngưỡng xấp xỉ 0.1667; ở demand cao, b=0, ngưỡng khoảng 0.1071. Discount 0.20 cao hơn cả hai nên kém tức thời trong các tình huống này. Đây là phân tích độ nhạy giữ nguyên conversion uplift; trong thị trường thật uplift có thể phụ thuộc mức giảm, nên không được dùng công thức làm quy tắc kinh doanh trực tiếp.

12 Thảo luận về độ tin cậy, giới hạn và diễn giải

Có ba lớp kết luận cần phân biệt. Lớp tính toán là những hệ quả trực tiếp của công thức, như margin 5 và 3 hoặc kỳ vọng 35. Lớp thực nghiệm là các mean/SD đo từ seed cụ thể. Lớp giải thích là giả thuyết về vì sao alpha cao hoặc khám phá nhiều gây policy kém; muốn xác định nguyên nhân cần ablation thêm. Báo cáo duy trì ranh giới này trong mọi bảng và lời giải.

Multiple seeds cải thiện tính tin cậy nội bộ nhưng không sửa mô hình kinh tế sai. Five-seed means còn chịu cả nhiễu training và evaluation vì seed pair thay cùng nhau; báo cáo không giả rằng đã tách riêng hai nguồn phương sai. Muốn phân rã, cần nhiều evaluation tapes cho mỗi fixed trained policy và nhiều training seeds độc lập.

Common random numbers giảm nhiễu so sánh nhưng không biến policy thành độc lập. Các policy có history khác nhau, nên cùng noise tape có thể dẫn đến state khác nhau. Điều này hợp lệ và là phản ứng của môi trường. So sánh phải giữ đúng opponent, reset và horizon để không trộn các thay đổi ngoài ý muốn.

Tương tác thị trường toy còn thiếu nhiều cơ chế. Hai cửa hàng có thể bán tổng nhiều hơn số khách hàng nếu hiểu khách hàng như một tập độc quyền; do đó nên coi N là số cơ hội mua cho mỗi cửa hàng theo mô hình, không làm kết luận thị phần. Reward không có tiền tệ thật, không có chiến dịch hoặc customer segments; mọi đề xuất triển khai đều cần dữ liệu và thiết kế riêng.

13 Kiểm tra độc lập bằng đánh giá policy chính xác

Ngoài Monte Carlo evaluation, báo cáo đã tính kỳ vọng policy bằng forward occupancy trên full state. Tệp `analyze_exact.py` lan truyền xác suất trạng thái qua 20 bước, cộng reward kỳ vọng thay vì lấy mẫu sales. Phép tính dùng cùng luật opponent, reset và horizon; vì vậy cung cấp mốc kiểm số liệu độc lập với random tape.

Seed 11/55 của baseline có policy 0000 và exact mean 35. Seed 44 có policy 0001 nhưng các trạng thái dẫn tới discount không tới được từ reset, nên exact mean vẫn 35. Seed 22/33 có policy 1000 và exact mean xấp xỉ 32.448. Chuỗi bit theo thứ tự (0,0), (0,1), (1,0), (1,1). Các state không tới được giải thích vì sao bảng policy khác nhau vẫn có cùng hiệu năng.

Lượt seed 42 có exact mean xấp xỉ 25.698, gần sample mean 25.5591. Khoảng cách lớn với 35 vì thế thuộc chất lượng policy, không đơn thuần một evaluation tape quá xấu. Bảng

exact của 25 cấu hình/seed được giữ trong `exact_policy_values.csv`; notebook hiển thị toàn bộ và giải thích phương pháp. Phân tích này không tạo thêm training run hoặc thay đổi kết quả đã đo.

14 Kết luận của assignment

Bài lab đã được hoàn thành với mã chạy, tách train/evaluation, thí nghiệm A–E, ba alpha, ba epsilon, năm seed, stress discount 40%, self-play và oracle DP. Mười câu hỏi được trả lời bằng công thức, số đo và giới hạn cụ thể. Các tệp CSV, Q-table, biểu đồ và notebook cho phép kiểm lại kết quả.

Trong môi trường tham chiếu, rule/never-discount là baseline rất mạnh, còn Q-learning có biến động theo seed và chưa vượt được mốc đó. Bài học chính là chất lượng của mô hình hóa, protocol và đối chứng quyết định ý nghĩa kết luận. Có học không bảo đảm tốt hơn luật, cũng như có nhiều agent không bảo đảm phối hợp hiệu quả.

15 Phụ lục kết quả đo và bằng chứng thực thi

Các bảng dưới được dựng trực tiếp từ CSV/JSON của lần chạy đầy đủ. Mọi mean cấu hình là trung bình qua năm seed 11, 22, 33, 44, 55; SD dùng ddof=1. Các ảnh là biểu đồ vẽ từ dữ liệu episode thực thi, không phải ảnh minh họa sinh bằng mô hình.

15.1 Bảng tổng hợp thí nghiệm alpha và epsilon

Cấu hình	Train mean	Eval mean	SD	CI95 ±	Discount (%)
baseline	33.6513	34.0997	1.3678	1.6981	16.16
alpha_001	32.0944	33.6484	2.1286	2.6425	19.91
alpha_050	31.8520	31.9533	4.1613	5.1661	38.08
epsilon_005	32.9458	33.3973	1.6126	2.0020	27.90
epsilon_030	30.8822	31.4300	3.9272	4.8755	33.88

15.2 So sánh công bằng với cùng đối thủ

Focal policy	Mean reward/step	SD giữa seed
RL	34.0997	1.3678
Rule	35.1295	0.1261
Never	35.1295	0.1261
Always	24.9722	0.0701
DP	35.1295	0.1261

15.3 Thí nghiệm biến đổi discount 40%

Policy	Mean reward/step	SD giữa seed
frozen_RL	32.6415	3.3620
retrained_RL	33.6009	3.3403
Rule	35.1295	0.1261
DP	35.1295	0.1261

15.4 Q-table minh họa seed 42

Demand	Opponent previous	Q(no discount)	Q(discount)	Greedy action
0	0	184.212867	199.449036	1
0	1	221.956047	181.668010	0
1	0	227.279761	235.197513	1
1	1	197.471701	218.162589	1

15.5 Từng seed của baseline

Seed	RL mean	Rule mean cùng tape	RL discount (%)
11	35.1825	35.1825	0.00
22	32.5267	35.0910	40.70
33	32.6863	35.2710	40.12
44	34.9350	34.9350	0.00
55	35.1680	35.1680	0.00

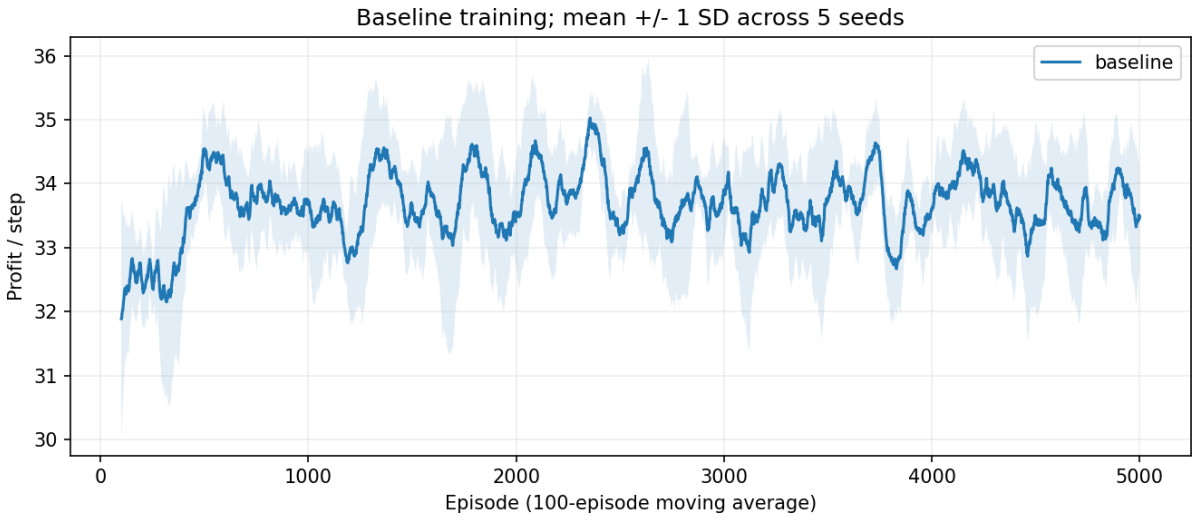
15.6 Cặp learner trong self-play

Seed	Learner	Eval mean	Discount (%)
11	0	30.5514	19.64
11	1	32.5935	40.21
22	0	35.0545	0.00
22	1	35.1300	0.00
33	0	35.3565	0.00
33	1	35.4800	0.00
44	0	34.8160	0.00
44	1	34.7835	0.00
55	0	34.8630	0.00
55	1	35.0500	0.00

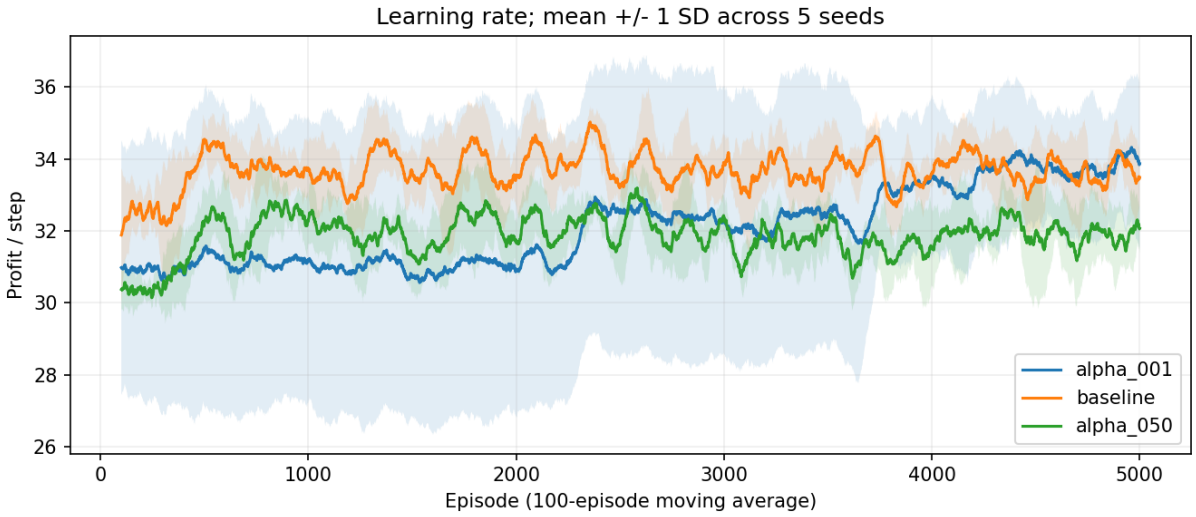
15.7 Đối chiếu bản gốc và bản mở rộng seed 42

Cùng seed số học không tạo cùng chuỗi khi cách dùng RNG khác. Bảng này ghi hai protocol riêng; không lấy chênh lệch làm bằng chứng chất lượng một thuật toán khác.

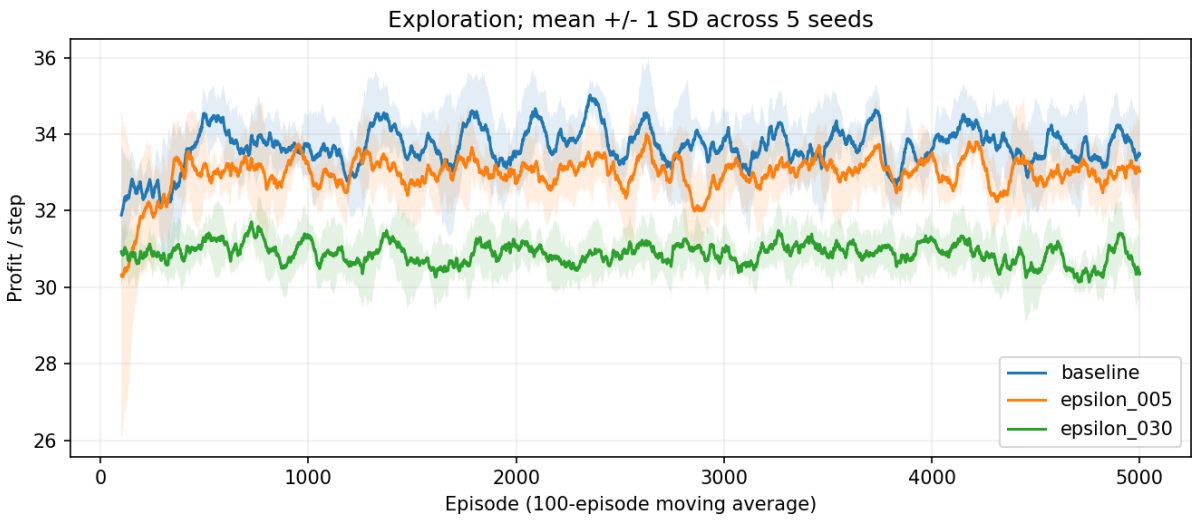
Protocol	Focal mean	Opponent mean
Code gốc nguyên văn	35.1275	34.9685
Bản mở rộng, split RNG	25.5591	24.6856



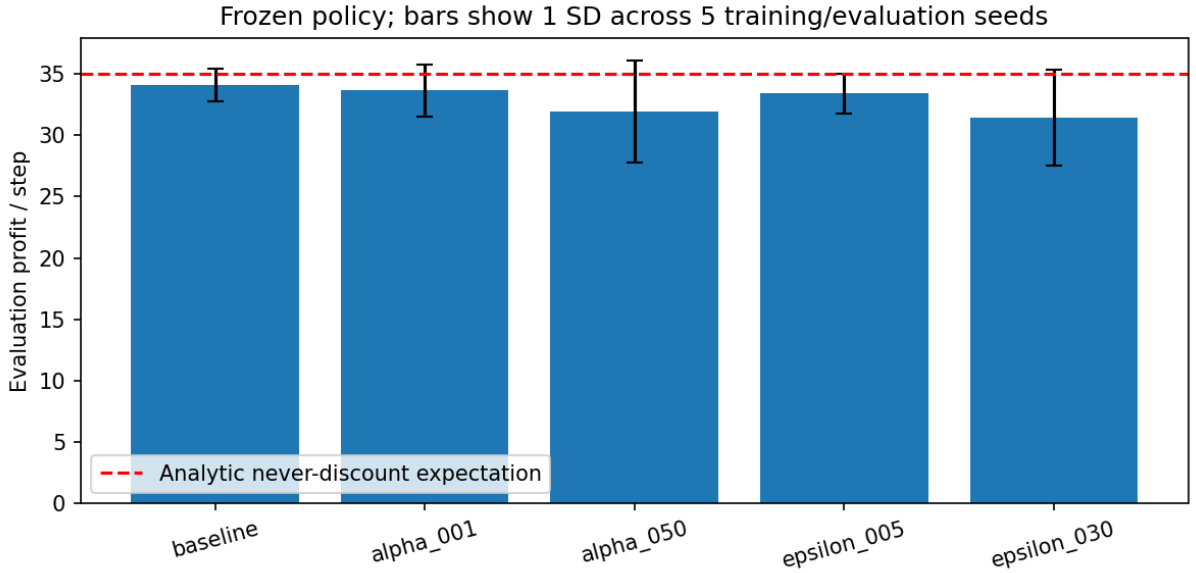
Hình 1: Learning curve baseline: moving average 100 episode, mean và một SD qua năm seed.



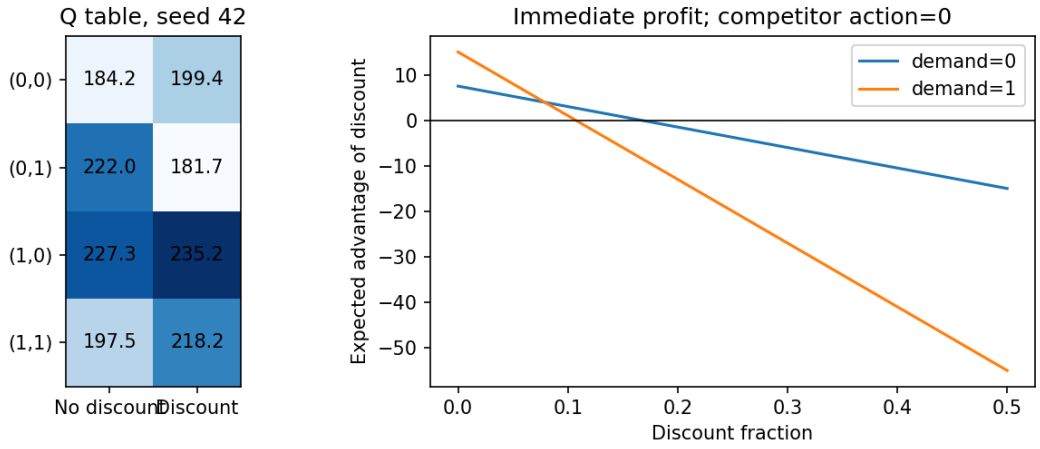
Hình 2: So sánh ba learning rate với cùng epsilon schedule.



Hình 3: So sánh ba cấu hình epsilon; mọi cấu hình đánh giá với epsilon bằng 0.



Hình 4: Policy đóng băng: mean và SD giữa seed; đường 35 là kỳ vọng lý thuyết.



Hình 5: Q-table seed 42 và độ nhạy lợi nhuận tức thời theo discount fraction.

15.8 Mã Python cốt lõi

Đây là các đoạn mã được lấy trực tiếp từ nguồn đã thực thi. Tệp đầy đủ và bản tham chiếu có trong thư mục assignment; các đoạn bên dưới đủ để kiểm cách cập nhật, tách evaluation và tính oracle.

Listing 1: Q-learning và luật, trích từ mã chạy

```
class QLearningAgent:
    def __init__(self, cfg=Config(), seed=10042):
        self.cfg=cfg; self.q=np.zeros((2,2,2)); self.rng=np.random.default_rng(seed)
    def act(self, state, epsilon=0.):
        if epsilon and self.rng.random()<epsilon: return int(self.rng.integers(2))
        q0,q1 = self.q[state]
        if epsilon and q0==q1: return int(self.rng.integers(2))
        return int(q1>q0)
    def learn(self,s,a,r,ns,terminal=False):
        target = r if terminal else r+self.cfg.gamma*float(max(self.q[ns]))
        idx=(*s,a); self.q[idx] += self.cfg.alpha*(target-self.q[idx])

class RuleBasedAgent:
    def act(self,state): return int(state[0]==1 and state[1]==1)
```

Listing 2: Quy hoạch động hữu hạn chân trời

```
def exact_best_response(cfg):
    """Finite-horizon DP on full Markov state (d, own_prev, opponent_prev).
    The fixed opponent's current action is d * own_prev; current actions simultaneous.
    """
    V=np.zeros((cfg.horizon+1,2,2,2)); policy=np.zeros((cfg.horizon,2,2,2),dtype=int)
    for t in range(cfg.horizon-1,-1,-1):
        for d in (0,1):
            for own in (0,1):
                for opp in (0,1):
                    b=d*own
                    values=[expected_profit(cfg,d,a,b)+cfg.gamma*np.mean(V[t+1,:,a,b]) for a in (0,1)]
                    policy[t,d,own,opp]=int(np.argmax(values)); V[t,d,own,opp]=max(values)
    return policy,V
```

Listing 3: Đánh giá đóng băng với common random numbers

```
def evaluate(cfg,policy='rule',opponent='rule',seed=800011):
    """500 episodes vectorized; demand and Bernoulli sales shared across policies.
    Q arrays are read-only inputs; np.argmax breaks exact ties toward action 0.
    """
    sd,ss=np.random.SeedSequence(seed).spawn(2)
    E,H=cfg.evaluation_episodes,cfg.horizon
    d=np.random.default_rng(sd).integers(2,size=(E,H))
    uniforms=np.random.default_rng(ss).random((E,H,2,20))
    prev=np.zeros((2,E),dtype=int); totals=np.zeros((2,E)); counts=np.zeros((2,2),dtype=int)
    def actions(p,idx,t):
        if isinstance(p,str):
            if p=='rule': return d[:,t]*prev[1-idx]
            if p=='never': return np.zeros(E,dtype=int)
            if p=='always': return np.ones(E,dtype=int)
            raise ValueError(p)
        if p.ndim==4: return p[t,d[:,t],prev[idx],prev[1-idx]]
        return np.argmax(p[d[:,t],prev[1-idx]],axis=-1)
    for t in range(H):
        acts=np.stack([actions(policy,0,t),actions(opponent,1,t)])
```

```
        for i in (0,1):
            p=conversion(d[:,t],acts[i],acts[1-i]); n=10+10*d[:,t]
            sales=((uniforms[:,t,i,:]<p[:,None]) & (np.arange(20)[None,:]<n[:,None])).sum(1)
            totals[i]+=sales*(cfg.price*(1-cfg.discount*acts[i])-cfg.cost)
            counts[i,1]+=int(acts[i].sum()); counts[i,0]+=int(E-acts[i].sum())
        prev=acts
    summary=[{'agent':name,'total_reward':float(totals[i].sum()),'mean_reward':float(totals[i].mean()/H),
              'episode_sd':float((totals[i]/H).std(ddof=1)), 'no_discount':int(counts[i,0]),
              'discount':int(counts[i,1]),'discount_rate':float(counts[i,1]/(E*H))} for i,name in enumerate
     (['focal','opponent'])]
    episodes=[{'episode':j+1,'focal_total':totals[0,j],'opponent_total':totals[1,j]} for j in range(E)]
    return summary,episodes
```

15.9 Bằng chứng kiểm thử

Bộ kiểm thử assignment có 12 ca, đã chạy thành công. Các ca kiểm công thức ví dụ 4.65; terminal không bootstrap; observation sau joint action; từ chối action sai; margin; bảng luật; Q không đổi khi đánh giá; tổng action counts; tái lập evaluation; DP chọn không giảm; tái lập training; và sample mean gần kỳ vọng 35 khi số episode lớn.

```
python3 -m unittest discover -s assignment -p 'test_*.py'
............
Ran 12 tests
OK
```

Log thực tế được giữ trong build/assignment_tests.log. Thời lượng đo cụ thể phụ thuộc máy, nên không dùng thời lượng test làm chỉ số thuật toán. Mười hai test không chứng nhận mô hình kinh tế đúng ngoài thực tế; chúng kiểm những bất biến quan trọng của implementation.

Tài liệu tham khảo

[1] PGS.TS. Trần Đình Quế (tài liệu môn học được cung cấp), *Developing Multiagent Systems: A Practical Tutorial with Python and PyTorch*, slide_multiAgent_system_20.10.2026.pdf, 25 trang, 2026. Nguồn cục bộ trong đề bài.

[2] *Laboratory Experiment 02: Reinforcement-Learning-Based Agents versus Rule-Based Agents*, Intelligent System Development, 2026–2027, assignment_Agent02_due_29.10.pdf, 13 trang; agent02_code.tex và agent02_complementary_code.pdf. Tài liệu cục bộ do người dùng cung cấp.

[3] K.-T. Tran, D. Dao, M.-D. Nguyen, Q.-V. Pham, B. O'Sullivan, H. D. Nguyen, *Multi-Agent Collaboration Mechanisms: A Survey of LLMs*, arXiv:2501.06322v1, 10/01/2025. https://arxiv.org/abs/2501.06322v1. Phân tích trực tiếp bản PDF 35 trang được cung cấp.

[4] M. Naeem, S. T. H. Rizvi, A. Coronato, *A Gentle Introduction to Reinforcement Learning and Its Application in Different Fields*, IEEE Access, vol. 8, pp. 209320–209344, 2020. DOI: 10.1109/ACCESS.2020.3038605. Phân tích trực tiếp bản PDF 25 trang được cung cấp.

[5] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018. Tài liệu nền tảng được cả slide và paper RL dẫn chiếu.

[6] C. J. C. H. Watkins, P. Dayan, *Q-learning*, Machine Learning 8, 279–292, 1992. DOI: 10.1007/BF00992698.

[7] Q. Wu et al., *AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation*, 2023. https://arxiv.org/abs/2308.08155.

[8] S. Hong et al., *MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework*, 2023, bản cập nhật 2024. https://arxiv.org/abs/2308.00352.

[9] Y. Du, S. Li, A. Torralba, J. B. Tenenbaum, I. Mordatch, *Improving Factuality and Reasoning in Language Models through Multiagent Debate*, 2023. https://arxiv.org/abs/2305.14325.

[10] PyTorch, *CrossEntropyLoss*, tài liệu chính thức. https://docs.pytorch.org/docs/stable/generated/torch.nn.CrossEntropyLoss.html. Đối chiếu giao diện ngày 28/10/2026; môi trường thực nghiệm dùng PyTorch 2.8.0.

[11] Python documentation, *Coroutines and Tasks: asyncio.wait_for*. https://docs.python.org/3/library/asyncio-task.html. Phần timeout được kiểm trực tiếp bằng tests trong môi trường thực thi.

[12] Bộ mã và dữ liệu tự thực thi của báo cáo: tutorial/, assignment/, results/, build/; seed và cấu hình lưu trong summary.json, intent_metrics.json và mas_metrics.json, ngày 28/10/2026. Đây là nguồn kết quả mô phỏng, không phải nguồn dữ liệu thị trường thực tế.